

Métricas, datos y calibración inteligente

L. A. Núñez *Escuela de Física, Facultad de Ciencias*

1. El problema

Estamos viviendo una época de desarrollo explosivo de sensores que pueblan y generan datos en todas las facetas de nuestra cotidianidad. Estos sensores de bajo costo forman parte de dispositivos de la llamada revolución de la *Internet de las cosas*, *IoT*. Muchas veces estos sensores no son lo suficientemente precisos y deben ser calibrados con un patrón de referencia (para un ejemplo de este tipo de calibraciones inteligentes pueden consultar [?]). Este ejercicio busca mostrar que esa calibración está íntimamente ligada a la idea de métrica (pueden consultar [?]).

El problema está en cuantificar cuál es el error de medición del sensor de bajo costo y cómo calibrarlo para que podamos establecer nuevas lecturas que sean más precisas.

En el directorio del pie de página¹ podrán encontrar los datos de referencia y los de las estaciones *IoT*. El archivo *Datos Estaciones AMB* contiene las medidas de referencia de concentración de material particulado (PM_{2,5}), es decir: concentración de partículas en suspensión de dimensiones $\leq 2,5 \mu\text{m}$. Los archivos etiquetados como *mediciones...* contienen los registros de las estaciones de bajo costo.

2. Una posible estrategia para calcular la distancia

Para comenzar es importante estimar la distancia entre las medidas de las estaciones de referencia y de las de bajo costo. Para ello utilizamos la distancia euclídea entre las dos mediciones:

$$\mathcal{D}(\mathbb{D}, \hat{\mathbb{D}}) = \sqrt{\sum_k (D_k - \hat{D}_k)^2} \quad (1)$$

Donde hemos definido $\mathbb{D} = \{(x_1, y_1), \dots, (x_n, y_n)\}$ al conjunto de datos de referencia y $\hat{\mathbb{D}} = \{(\hat{x}_1, \hat{y}_1), \dots, (\hat{x}_m, \hat{y}_m)\}$ al conjunto de datos a calibrar. En la práctica es conveniente

¹<https://github.com/nunezluis/MisCursos/tree/main/MisMateriales/Asignaciones/TallerDistancias/DatosDistancias>

emparejar las mediciones cercanas en tiempo (por ejemplo mediante una ventana) y calcular la distancia sobre los promedios locales.

Claramente, estamos identificando por $f(x_i) = y_i$ el valor de la variable dependiente (en este caso la concentración de material particulado) medido por la estación patrón, y las mediciones de la estación a calibrar por $\hat{f}(\hat{x}_i) = \hat{y}_i$. Además, las dimensiones de los conjuntos pueden diferir ($n \neq m$) y por eso se requiere una regla para emparejar puntos cercanos en tiempo.

Una posible estrategia para identificar los datos "más cercanos" es utilizar el criterio del promedio móvil² y comparar los promedios locales de ambos conjuntos $f(\xi_j)$ y $\hat{f}(\xi_j)$, calculados para una ventana común $a_j \leq x_i, \hat{x}_i \leq b_j$. Una elección natural es tomar $\xi_j = a_j + (b_j - a_j)/2$, donde j indica el número de ventanas definidas en el rango de variación de los datos.

Definir el ancho de la ventana para calcular los promedios locales es un arte y requiere experimentación para balancear el tiempo de cálculo con la precisión lograda. Entonces, **calcule la distancia euclídea $\mathcal{D}(\mathbb{D}, \hat{\mathbb{D}})$ para varios valores de la ventana móvil y determine el mejor valor para la ventana.**

3. Una posible estrategia para calibrar las mediciones

Si graficamos los puntos $(\hat{f}(\xi_j), f(\xi_j))$ y hacemos un ajuste de mínimos cuadrados podremos determinar un modelo lineal de la forma

$$f(\xi_j) = \alpha \hat{f}(\xi_j) + \beta \quad (2)$$

aunque en muchas situaciones sencillas basta con usar $f(\xi_j) = \alpha \hat{f}(\xi_j)$ (siempre que la intersección pueda asumirse cero). Claramente si ambas estaciones midieran lo mismo, tendríamos $\alpha = 1$ y $\beta = 0$.

Determine el alcance de validez del modelo lineal. Es decir, defina una tolerancia (error aceptable) y encuentre el rango en las mediciones $\hat{x}_i$ donde el modelo lineal cumple esa tolerancia.

Otra estrategia es dividir los conjuntos de datos en subconjuntos de entrenamiento y validación. Por ejemplo, usar la primera mitad para ajustar el modelo

$$\mathbb{D}_1 = \{(x_1, y_1), \dots, (x_{\lfloor n/2 \rfloor}, y_{\lfloor n/2 \rfloor})\}$$

y verificar la predicción del modelo sobre la segunda mitad

$$\mathbb{D}_2 = \{(x_{\lfloor n/2 \rfloor + 1}, y_{\lfloor n/2 \rfloor + 1}), \dots, (x_n, y_n)\}$$

²https://en.wikipedia.org/wiki/Moving_average

Determine cuál es el alcance de predicción dentro de la tolerancia definida.

El tamaño mínimo necesario para generar un modelo y su alcance de predicción depende fuertemente de la dinámica de los datos. **Determine el tamaño mínimo de datos para generar el modelo y su máximo alcance para una tolerancia dada.**